王朗

大模型 Infra / AI Agent 工程化 / 推理基础设施工程师

LLM Inference | AI Agent Harness | GPU / NPU | CUDA Kernel

PROFILE

近两年专注大模型 Infra、推理基础设施与 AI Agent 工程化，参与 MindGPT、MindVLA、LisaRT 等核心项目研发与交付。Vibe Coding 分享者与拥护者，系统实践 Claude Code / Managed Agents / long-running harness，将工程师角色从直接编码扩展为 Agent 监督者与 Harness 设计者。熟悉 TensorRT-LLM、TensorRT、CUTLASS、FlashInfer、DeepGEMM、cuDNN Frontend，具备 GPU/NPU 架构优化、模型评估、引擎拉通、算子优化、精度对齐、性能评测与稳定性排障经验。

EDUCATION

中国科学院大学

网络空间安全学院 | 硕士研究生
高性能计算方向 | 2021.09 - 2024.06

北京信息科技大学

计算机科学与技术 | 本科
2015.09 - 2019.06

SKILLS

推理基础设施

LisaRT / TensorRT-LLM / TensorRT / SGLang / TRT engine / 精度对齐 / 稳定性排障 / barrier removal

CUDA / 算子优化

CUTLASS / DeepGEMM / FlashInfer / cuDNN Frontend / cuBLASLt / CUDA Graph / TM 地址分配

AI Agent 工程化

Vibe Coding / Claude Code / Managed Agents / Planner-Generator-Evaluator / Memory / Skills / Subagents / 自动评测闭环

性能分析

Nsight Compute / simpleperf / cutlass_profiler / roofline / occupancy / NUMA / NCCL

EXPERIENCE

理想汽车 | AI 引擎 / 大模型 Infra

2024.07 – 至今

AI Agent / Vibe Coding 工程化与技术分享

- Vibe Coding 分享者与拥护者，围绕 Claude Code 工作流、上下文工程、CLAUDE.md / Memory / Skills / Subagents、Plan Mode、worktree 隔离、提示词工程等主题沉淀方法论，推动团队从“使用 AI 编码”升级为“设计 Harness 管理 Agent”。
- 设计面向长时间系统优化任务的 Agent Harness，将 Planner、Generator、Evaluator、Memory 解耦，通过多 worktree 并行探索、独立评估、session log 持久化和自动化回归验证支持复杂优化持续收敛。
- VLIW-SIMD 优化实验：通过多 Agent 竞争 + Perf Agent trace 评估 + 增量融合，将 cycles 从 **147,734 降至 1,391**，取得 **106.2x** 加速，超过 Claude Opus 4.5 发布时最佳记录 1,487 cycles。
- AI Agent 主导 H800 dense attention forward kernel 优化，Round 17 latency 达到 **0.303ms**，超过 FlashInfer 0.6.8 baseline **0.311ms**。

MindGPT3.x 大模型推理基础设施优化

- 参与 MindGPT3.0 / 3.1 推理基础设施优化，覆盖 MOE、MLA、GEMM、Attention、Sampling、内存稳定性等关键链路，支撑大模型推理性能与线上稳定性提升。
- 分析 TensorRT-LLM MOE 流程并接入 deep-groupgemm，group GEMM kernel 相比 CUTLASS 版本加速约 **55%**；MOE 前处理从 **14ms 降至 279us**，后处理从 **3ms 降至 339us**。
- 优化 MOE prefill：TP16 场景从 **712ms 降至 612ms**，加速 16.3%；EP16 场景从 **484ms 降至 434ms**，加速 11.5%。
- 基于 FlashInfer 优化采样层：非投机采样从 **2.21ms 降至 0.11ms**，decode 吞吐从 **78.37 提升至 96.15 token/s**；投机采样最高加速约 70%。
- 使用 cutlass_profiler 调优高 batch GEMM，取得 **50%~70%** GEMM 性能收益；定位 NCCL 版本导致的 CPU 内存泄漏并完成 A800 / H800 / H100 24 小时压测验证。

MindVLA 端云推理能力建设与交付

- 负责 MindVLA 端云推理链路拉通与优化，覆盖模型选型、TRT engine 转换、精度对齐、稳定性排查和跨团队交付。
- 优化云侧 MambaViT / Hybrid ViT，从初版 NHWC 拉通 **33.0ms 优化至 7.25ms**，性能优于未开 CUDA Graph 的 TensorRT（7.25ms vs 7.5ms）。
- 2k batch2 场景完成 Hybrid-ViT Mamba TRT 拉通与优化，P95 TTFT 达到 **105ms**，优于 1k ViT 方案 114ms。
- 定位 NUMA 导致的推理波动，将单算子波动指数从 **7.44 降至 0.42**，下降 94.35%；单路 TTFT 波动指数从 **18.07 降至 3.41**，下降 81.13%。
- 支撑端侧 MindViT 选型与调优，使 OrinX 从 **15.2ms 降至 11.1ms**，ThorU 从 **9.3ms 降至 8.1ms**。

M100 MoE2.0 / Attention 同步优化与 TM 地址分配

- 参与 M100 MoE2.0 Attention 层适配与同步优化，将 barrier 同步逐步改造为信号量同步，完成关键 barrier removal，推动初版有效 token 输出与 Golden bit-wise 对齐，并进入指令并行执行优化阶段。
- 设计基于生命周期冲突图与贪心装箱的 TM 基址生成方法，建模 loop transient / persistent 生命周期、良性/恶性踩踏、非 in-place 约束和 allowed overlaps，在 2MB Tile Memory 约束下自动生成变量起始地址。
- 编写 barrier-removal harness，用于约束 Claude Code 移除 barrier 的工作流，沉淀从观测、假设、修改到 bit-wise 验证的同步优化流程。